


HADOOP E SPARK

LABORATÓRIO

GRUPO



Gabryel Nicolas
221022570



Guilherme Westphall
211061805



Joel Soares
211039546



Lucas Martins
221022088

HADOOP

- Simulação de um cluster com Docker Compose
- Contabilização de palavras em arquivos grandes (Word Count)
- Testes de performance
- Testes de Falha

CLUSTER

Composto por 8 containêres:

Serviço	Função	Porta
nn	NameNode – Gerencia o sistema de arquivos distribuído (HDFS).	9870 / 9000
dn1 , dn2	DataNodes – Armazenam blocos reais de dados do HDFS.	9864
rm	ResourceManager – Coordena e agenda tarefas do YARN.	8088 / 8032
nm1 , nm2	NodeManagers – Executam containers de tarefas (Map/Reduce).	8042
jhs	JobHistoryServer – Armazena logs e histórico de execuções.	19888
edge	Client Node – Ponto de entrada para comandos <code>hdfs</code> , <code>yarn</code> , <code>mapred</code> .	—

WORD COUNT

Geração do arquivo e execução do job MapReduce

```
yes "lorem ipsum dolor sit amet" | head -n 300000000 > /tmp/big.txt  
hdfs dfs -put /tmp/big.txt /jobs/big.txt
```

```
EX=$(ls /home/hadoop/hadoop/share/hadoop/mapreduce/hadoop-mapreduce-examples-*.jar | head -n1)  
hadoop jar "$EX" wordcount /jobs/big.txt /jobs-out-baseline
```

```
hdfs dfs -cat /jobs-out-baseline/part-r-00000
```

TESTE DE PERFORMANCE

Mudança de 5 características

Cenário	Job ID	Replicação	Blocksize	Memória NM	Tempo (s)	Throughput (MB/s)	CPU total (s)	GC total (s)	Memória física snapshot (GB)*
Baseline	job_1763235544715_0002	1	128 MB	2048 MB	598,616	12,90	≈ 1843,6	≈ 87,7	≈ 19,0
2 réplicas	job_1763236505643_0001	2	128 MB	2048 MB	396,503	19,48	≈ 1833,2	≈ 84,3	≈ 19,2
Blocksize = 64 MB	job_1763237020860_0001	1	64 MB	2048 MB	374,766	20,61	≈ 1853,1	≈ 93,7	≈ 19,1
Blocksize = 256 MB	job_1763237525385_0001	1	256 MB	2048 MB	382,375	20,20	n/d	n/d	n/d
NodeManager = 4 GB	job_1763242547198_0001	1	128 MB	4096 MB	373,000	20,71	≈ 1872,3	≈ 83,2	≈ 17,4

TESTE DE FALHA

Provocação controlada de condições adversas

Etapa	Ação realizada	Estado do job / progresso	Comportamento observado
1	Job submetido normalmente	map 0% → 10%	Execução normal, avanço gradual sem erros aparentes.
2	Queda do dn1 (um DataNode fora)	~map 10–20%	Job continua executando, porém mais lento; não ocorre falha imediata.
3	Queda do dn2 (ambos DataNodes offline)	~map 23%	Execução congela; surgem erros <code>BlockMissingException</code> devido à ausência de réplicas disponíveis.
4	Subida de dn1 e dn2	~map 23% → 30%+	Job imprime avisos de falha, mas retoma a execução a partir do ponto em que estava.
5	Queda do NameNode	progresso em map/reduce	Job congela imediatamente; são emitidos erros relacionados ao acesso aos metadados do HDFS.
6	Subida do NameNode	mesmo progresso inicial	Job é retomado; progresso avança normalmente após o retorno do serviço.
7	Finalização do job	100% map / 100% reduce	Apesar das falhas, a tarefa finaliza com sucesso , com várias tentativas marcadas como FAILED/RELAUNCHED.

SPARK STREAMING

- Produtor de dados de entrada
- Conecta-se à API do Discord, monitora mensagens e as escreve no tópico canalinput do Kafka

Bot
Discord

Kafka

Spark

Kafka
Connector

Elastic
Search

Kibana

Ngrok

SPARK STREAMING

- Fila de mensagens distribuída e buffer de dados, atua como intermediário
- Recebe os dados brutos do Discord (canalinput) e recebe os resultados processados pelo spark (canaloutput)

Bot
Discord

Kafka

Spark

Kafka
Connector

Elastic
Search

Kibana

Ngrok

SPARK STREAMING

- Motor de processamento de dados em tempo real (Word Count)
- Lê o fluxo de dados do canalinput, separa as mensagens em palavras e conta a frequência de cada palavra

Bot
Discord

Kafka

Spark

Kafka
Connector

Elastic
Search

Kibana

Ngrok

SPARK STREAMING

- Agente de transferência de dados
- Lê o resultado da contagem de palavras (canaloutput) e envia os registros para o Elastic Search

Bot
Discord

Kafka

Spark

Kafka
Connector

Elastic
Search

Kibana

Ngrok

SPARK STREAMING

- Banco de dados/motor de busca para análise em tempo real
- Recebe e armazena os dados de contagem de palavras do Kafka Connector
- Indexa os campos word e count para permitir consultas e agregações

Bot
Discord

Kafka

Spark

Kafka
Connector

Elastic
Search

Ngrok

Kibana

SPARK STREAMING

- Interface de visualização, dashboard
- Conecta-se ao ElasticSearch, utiliza o Index Pattern (canaloutput*) para entender a estrutura dos dados e renderiza as visualizações, como a Nuvem de Palavras

Bot
Discord

Kafka

Spark

Kafka
Connector

Elastic
Search

Kibana

Ngrok

SPARK STREAMING

- Túnel de exposição de serviço local
- Cria um túnel seguro (URL pública) para a porta local onde o Kibana está rodando (porta 5601), permitindo acesso da interface web no navegador

Bot
Discord

Kafka

Spark

Kafka
Connector

Elastic
Search

Kibana

Ngrok

NUVEM DE PALAVRAS



OBRIGADO